



**ECOLE MAROCAINE DES
SCIENCES DE L'INGENIEUR**

Membre de **HONORIS UNITED UNIVERSITIES**

Projet de module Exploration de données

Prédiction de la consommation de carburant
automobile

Auto MPG Dataset

Réalisé par :

Mr Omar Tazi

Mlle Meriam Erragragui

Encadrant Pédagogique :

Pr. NADIR Younes

Année universitaire 2025-2026

Dédicaces

À mes parents, pour leur soutien indéfectible et leurs sacrifices.
À mes professeurs, pour leur passion et leur dévouement.
À mes camarades, pour les moments de partage et d'entraide.
À tous ceux qui croient en moi.

"Le succès n'est pas final, l'échec n'est pas fatal : c'est le courage de continuer qui compte."

Remerciements

Je tiens à remercier tout particulièrement mon encadrant pédagogique, Pr. NADIR Younes, pour ses précieux conseils, sa disponibilité et son accompagnement tout au long de ce projet.

Je remercie également l'ensemble des enseignants du module Exploration de données pour la qualité de leur enseignement et les connaissances transmises.

Enfin, je remercie mes camarades de promotion pour leur entraide et les échanges fructueux qui ont contribué à l'avancement de ce travail.

Résumé

Ce projet s'inscrit dans le cadre du module Exploration de données et porte sur la prédiction de la consommation de carburant des véhicules automobiles à partir de leurs caractéristiques techniques. Le jeu de données utilisé, *Auto MPG Dataset*, provient de l'UCI Machine Learning Repository et contient 398 observations de véhicules datant de 1970 à 1982.

La problématique consiste à déterminer s'il est possible de prédire la consommation en miles per gallon (mpg) à partir de variables telles que le poids, la puissance, la cylindrée, le nombre de cylindres, l'année de fabrication et l'origine géographique du véhicule. Il s'agit d'un problème de régression supervisée.

Notre démarche a suivi les étapes classiques du Data Mining : chargement et exploration des données, analyse de la qualité des données, nettoyage (imputation des valeurs manquantes), analyse exploratoire approfondie, prétraitement (standardisation, encodage), modélisation avec quatre algorithmes (Régression Linéaire, Ridge, Lasso et Random Forest) et évaluation des performances.

Les résultats montrent que le modèle Random Forest surpasse les modèles linéaires avec un coefficient de détermination R^2 de 0.912 sur l'ensemble de test. L'analyse de l'importance des variables révèle que le poids est le facteur le plus influent (51%), suivi de l'année du modèle (21%) et de l'origine géographique.

Les principales limites du projet concernent l'ancienneté des données (1970-1982) qui ne reflète pas les technologies modernes, la taille modeste du dataset et l'absence de variables clés comme le type de carburant ou la transmission.

Mots-clés : Data Mining, Régression, Auto MPG, Random Forest, Consommation de carburant, Analyse exploratoire.

Abstract

This project is part of the Data Exploration module and focuses on predicting automotive fuel consumption based on technical vehicle characteristics. The dataset used, *Auto MPG Dataset*, comes from the UCI Machine Learning Repository and contains 398 vehicle observations from 1970 to 1982.

The research question is whether it is possible to predict fuel consumption in miles per gallon (mpg) using variables such as weight, horsepower, displacement, number of cylinders, model year, and geographic origin. This is a supervised regression problem.

Our methodology followed standard Data Mining steps : data loading and exploration, data quality analysis, cleaning (missing value imputation), in-depth exploratory analysis, preprocessing (standardization, encoding), modeling with four algorithms (Linear Regression, Ridge, Lasso, and Random Forest), and performance evaluation.

Results show that the Random Forest model outperforms linear models with an R^2 of 0.912 on the test set. Feature importance analysis reveals that weight is the most influential factor (51%), followed by model year (21%) and geographic origin.

The main limitations concern the age of the data (1970-1982), which does not reflect modern technologies, the modest dataset size, and the absence of key variables such as fuel type or transmission.

Keywords : Data Mining, Regression, Auto MPG, Random Forest, Fuel Consumption, Exploratory Analysis.

Table des matières

Dédicaces	1
Remerciements	2
Résumé	3
Abstract	4
Liste des figures	7
Liste des tableaux	8
Liste des abréviations	9
Introduction générale	10
1 Présentation du projet et du dataset	11
1.1 Introduction du chapitre	11
1.2 Présentation du domaine d'application	11
1.3 Présentation du problème étudié	11
1.4 Présentation du dataset	11
1.5 Description des variables	12
1.6 Objectifs analytiques du projet	12
1.7 Planning du travail	13
1.8 Conclusion du chapitre	13
2 Analyse exploratoire et préparation des données	14
2.1 Introduction du chapitre	14
2.2 Chargement et aperçu initial des données	14
2.3 Analyse de la variable cible	14
2.4 Analyse exploratoire des variables	14
2.4.1 Relation poids vs consommation	14
2.4.2 Relation puissance vs consommation	15
2.4.3 Consommation par nombre de cylindres	15
2.4.4 Évolution temporelle	15
2.4.5 Consommation par origine	15
2.5 Qualité des données	15
2.6 Feature engineering	15
2.7 Prétraitement des données	16
2.8 Conclusion du chapitre	16
3 Modélisation, expérimentation et évaluation	17
3.1 Introduction du chapitre	17
3.2 Choix des algorithmes	17
3.3 Protocole expérimental	17
3.4 Métriques d'évaluation	17
3.5 Résultats obtenus	18

3.6	Analyse des erreurs	18
3.7	Importance des variables	18
3.8	Sélection du meilleur modèle	19
3.9	Conclusion du chapitre	19
4	Interprétation, limites et reproductibilité	20
4.1	Introduction du chapitre	20
4.2	Interprétation des résultats	20
4.3	Discussion métier ou applicative	20
4.4	Limites du travail	20
4.5	Améliorations possibles	20
4.6	Reproductibilité du projet	21
4.7	Structure obligatoire du notebook	21
4.8	Conclusion du chapitre	21
	Conclusion générale	22
	Bibliographie et Nétographie	23
	ANNEXES	24

Table des figures

1	Visualisations de l'analyse exploratoire (EDA)	24
2	Matrice de corrélation des variables numériques	25
3	Prédictions vs valeurs réelles - Random Forest	25
4	Analyse des résidus du modèle Random Forest	26
5	Importance des variables dans le modèle Random Forest	26

Liste des tableaux

1	Liste des abréviations	9
2	Synthèse du problème étudié	11
3	Description générale du dataset	12
4	Dictionnaire simplifié des variables	12
5	Planning prévisionnel du projet Data Mining	13
6	Vérifications initiales du dataset	14
7	Analyse de la qualité des données	15
8	Synthèse du prétraitement	16
9	Choix des algorithmes pour la régression	17
10	Protocole expérimental	17
11	Métriques d'évaluation pour la régression	18
12	Comparaison des modèles de régression	18
13	Importance des variables	18
14	Informations de reproductibilité	21
15	Structure obligatoire du notebook	21

Liste des abréviations

TABLE 1 – Liste des abréviations

Abréviation	Signification
EDA	Exploratory Data Analysis / Analyse exploratoire des données
ML	Machine Learning
RMSE	Root Mean Squared Error / Erreur quadratique moyenne
MAE	Mean Absolute Error / Erreur absolue moyenne
R^2	Coefficient de détermination
UCI	University of California Irvine
CSV	Comma-Separated Values

Introduction générale

Contexte général

L'industrie automobile est aujourd'hui confrontée à des enjeux majeurs liés à la transition énergétique et aux réglementations environnementales. La réduction de la consommation de carburant et des émissions de CO est devenue une priorité tant pour les constructeurs que pour les pouvoirs publics. Dans ce contexte, l'analyse de données et le Data Mining offrent des outils puissants pour comprendre les facteurs influençant l'efficacité énergétique des véhicules et pour prédire leur consommation à partir de leurs caractéristiques techniques.

Problématique

La question centrale de ce projet est : **Peut-on prédire la consommation de carburant d'une voiture (en miles per gallon) à partir de ses caractéristiques techniques telles que le poids, la puissance, la cylindrée, le nombre de cylindres, l'année de fabrication et son origine géographique ?**

Il s'agit d'un problème de **régression supervisée**, où la variable cible est **mpg** (miles per gallon), et les variables explicatives sont les caractéristiques techniques du véhicule.

Objectifs du projet

Les objectifs de ce projet sont :

- Comprendre le dataset et sa source (UCI Machine Learning Repository).
- Analyser les variables et la cible.
- Nettoyer et préparer les données.
- Réaliser une analyse exploratoire commentée.
- Construire plusieurs modèles de régression adaptés.
- Évaluer les performances avec des métriques pertinentes.
- Interpréter les résultats et discuter les limites.

Organisation du rapport

Le premier chapitre présente le cadre du projet et le dataset. Le deuxième chapitre décrit l'analyse exploratoire et la préparation des données. Le troisième chapitre expose la modélisation, les expérimentations et l'évaluation. Le quatrième chapitre présente l'interprétation, les limites, les perspectives et les éléments de reproductibilité.

1 Présentation du projet et du dataset

1.1 Introduction du chapitre

Ce chapitre présente le cadre général du projet, le domaine d'application, la problématique étudiée et le jeu de données utilisé. Nous décrivons les variables disponibles, leurs types et leurs rôles, puis nous présentons les objectifs analytiques du projet. Enfin, un planning prévisionnel des travaux est proposé.

1.2 Présentation du domaine d'application

Ce projet s'inscrit dans le domaine de l'industrie automobile et de l'efficacité énergétique. La prédiction de la consommation de carburant est un enjeu majeur pour :

- Les **constructeurs automobiles** : pour concevoir des véhicules plus économes.
- Les **consommateurs** : pour faire des choix éclairés lors de l'achat d'un véhicule.
- Les **pouvoirs publics** : pour définir des normes d'émissions et des incitations fiscales.

L'analyse de données permet d'identifier les facteurs clés influençant la consommation et de quantifier leur impact.

1.3 Présentation du problème étudié

Le problème consiste à prédire la consommation de carburant d'un véhicule (mesurée en mpg) à partir de ses caractéristiques techniques. Il s'agit d'une tâche de régression supervisée.

TABLE 2 – Synthèse du problème étudié

Élément	Description attendue
Problème à résoudre	Prédire la consommation de carburant (mpg) d'un véhicule à partir de ses caractéristiques techniques.
Type de tâche	Régression supervisée
Variable cible	mpg (miles per gallon) - variable continue
Intérêt du modèle	Aide à la conception de véhicules plus économes, estimation de la consommation pour les acheteurs, analyse des tendances d'efficacité énergétique.

1.4 Présentation du dataset

Le jeu de données **Auto MPG** provient de l'UCI Machine Learning Repository.

TABLE 3 – Description générale du dataset

Élément	Description
Nom du dataset	Auto MPG Dataset
Source	UCI Machine Learning Repository
Lien officiel	https://archive.ics.uci.edu/ml/datasets/Auto+MPG
Domaine	Automobile / Efficacité énergétique
Nombre de lignes	398
Nombre de colonnes	9
Type de tâche	Régression
Variable cible	mpg (miles per gallon)

1.5 Description des variables

Le tableau ci-dessous décrit les variables du dataset.

TABLE 4 – Dictionnaire simplifié des variables

Variable	Type	Description	Rôle
mpg	Numérique	Consommation de carburant (miles per gallon)	Cible
cylinders	Numérique	Nombre de cylindres (3 à 8)	Feature
displacement	Numérique	Cylindrée du moteur (cubic inches)	Feature
horsepower	Numérique	Puissance du moteur (horsepower)	Feature
weight	Numérique	Poids du véhicule (lbs)	Feature
acceleration	Numérique	Temps d'accélération 0-60 mph (secondes)	Feature
model_year	Numérique	Année du modèle (70 à 82)	Feature
origin	Catégoriel	Origine : 1=USA, 2=Europe, 3=Japon	Feature
car_name	Identifiant	Nom du modèle	À exclure

1.6 Objectifs analytiques du projet

Les objectifs analytiques de ce projet sont :

- Explorer la structure du dataset et comprendre les relations entre les variables.
- Identifier les variables importantes influençant la consommation.
- Traiter les valeurs manquantes, les doublons et les incohérences.
- Créer des variables dérivées pertinentes si nécessaire.
- Comparer plusieurs modèles de régression pour identifier le plus performant.
- Sélectionner une approche selon des métriques adaptées (RMSE, MAE, R^2).
- Interpréter les résultats et discuter les limites.

1.7 Planning du travail

Le planning prévisionnel du projet est présenté ci-dessous.

TABLE 5 – Planning prévisionnel du projet Data Mining

Étape	S1	S2	S3	S4
Recherche et validation du dataset	X			
Compréhension du problème	X			
Analyse exploratoire		X	X	
Nettoyage des données			X	
Prétraitement			X	
Modélisation			X	
Évaluation				X
Interprétation et rapport				X

1.8 Conclusion du chapitre

Ce chapitre a présenté le contexte du projet, la problématique de prédiction de la consommation de carburant, le dataset Auto MPG de l'UCI, ses variables et ses objectifs analytiques. Le dataset contient 398 observations et 9 variables, avec pour cible la consommation en mpg. Le chapitre suivant sera consacré à l'analyse exploratoire et à la préparation des données.

2 Analyse exploratoire et préparation des données

2.1 Introduction du chapitre

Ce chapitre présente l'exploration du dataset, l'étude de la qualité des données, les visualisations réalisées et les traitements appliqués avant la modélisation. Nous analysons la structure des données, la distribution de la variable cible, les relations entre les variables, et nous traitons les problèmes de qualité des données.

2.2 Chargement et aperçu initial des données

Le dataset a été chargé à partir du fichier `auto-mpg.data` en utilisant la bibliothèque `pandas`. Les colonnes ont été nommées selon la documentation UCI.

TABLE 6 – Vérifications initiales du dataset

Élément à vérifier	Commande ou action attendue
Dimensions	<code>df.shape</code> → (398, 9)
Aperçu des données	<code>df.head()</code>
Types des colonnes	<code>df.info()</code>
Statistiques descriptives	<code>df.describe()</code>
Source du dataset	UCI : <code>auto-mpg.data</code>

Commentaire : Le chargement s'est effectué sans erreur. Le dataset contient 398 lignes et 9 colonnes. Les types de données sont corrects : les variables numériques sont de type `float64` ou `int64`, et la variable `car_name` est de type `object`.

2.3 Analyse de la variable cible

La variable cible `mpg` (miles per gallon) est une variable continue. Son analyse révèle :

- Une distribution **bimodale** : deux groupes de véhicules (économes et gourmands).
- Une moyenne de 23.5 mpg et une médiane de 23.0 mpg.
- Des valeurs allant de 9.0 à 46.6 mpg.

Cette distribution suggère que le modèle devra capturer cette bimodalité. Aucune transformation n'a été jugée nécessaire car la distribution n'est pas fortement asymétrique.

2.4 Analyse exploratoire des variables

L'analyse exploratoire a permis d'identifier les relations suivantes :

2.4.1 Relation poids vs consommation

Le poids et la consommation présentent une **forte corrélation négative** de **-0.83**. Chaque augmentation de 100 lbs réduit la consommation d'environ 0.7 mpg.

2.4.2 Relation puissance vs consommation

La puissance et la consommation présentent une corrélation négative de **-0.78**. Les véhicules les plus puissants ont les consommations les plus élevées.

2.4.3 Consommation par nombre de cylindres

- 4 cylindres : moyenne ≈ 29 mpg
- 8 cylindres : moyenne ≈ 15 mpg

2.4.4 Évolution temporelle

La corrélation avec l'année du modèle est de **+0.58**. Les véhicules plus récents sont significativement plus économes.

2.4.5 Consommation par origine

- Japon : moyenne ≈ 30 mpg (les plus économes)
- Europe : moyenne ≈ 25 mpg
- USA : moyenne ≈ 20 mpg (les plus gourmandes)

2.5 Qualité des données

L'analyse de la qualité des données a révélé les problèmes suivants :

TABLE 7 – Analyse de la qualité des données

Problème détecté	Colonnes concernées	Traitement appliqué	Justification
Valeurs manquantes	horsepower (6 valeurs, 1.5%)	Imputation par la médiane (93.5)	Distribution asymétrique, la médiane est plus robuste que la moyenne.
Doublons	Aucun	Conservation	Aucun doublon détecté.
Outliers	mpg, weight, horsepower, displacement, acceleration	Conservation	Les outliers représentent des véhicules réels. Leur suppression réduirait la représentativité.
Fuite de données	car_name	Exclusion	Identifiant unique, non pertinent pour la prédiction.

2.6 Feature engineering

Aucune variable dérivée n'a été créée car les variables existantes sont déjà pertinentes pour la modélisation. Toutefois, l'encodage de la variable **origin** en variables binaires a été réalisé lors du prétraitement.

2.7 Prétraitement des données

Le prétraitement a suivi les étapes suivantes :

TABLE 8 – Synthèse du prétraitement

Traitement	Méthode utilisée	Justification
Encodage	OneHotEncoder (drop='first')	Variable catégorielle origin (USA, Europe, Japon)
Imputation	Médiane	Valeurs manquantes de horsepower
Standardisation	StandardScaler	Variables numériques pour les modèles sensibles à l'échelle
Split	Train/Test 80/20 aléatoire	Évaluation fiable, reproductible (random_state=42)
Pipeline	Pipeline + Column-Transformer	Reproductibilité et éviter les fuites de données

2.8 Conclusion du chapitre

L'analyse exploratoire a révélé des relations importantes entre les variables et la consommation. Le poids est le facteur le plus influent. Les données ont été nettoyées (imputation des valeurs manquantes), et les outliers ont été conservés. Le prétraitement a permis de préparer les données pour la modélisation avec un pipeline standardisé. Le chapitre suivant présente la modélisation et l'évaluation des modèles.

3 Modélisation, expérimentation et évaluation

3.1 Introduction du chapitre

Ce chapitre présente les modèles ou algorithmes utilisés, les paramètres expérimentaux, les métriques choisies et les résultats obtenus. Quatre modèles de régression ont été comparés : Régression Linéaire, Ridge, Lasso et Random Forest.

3.2 Choix des algorithmes

Les algorithmes ont été choisis selon le type de tâche (régression) :

TABLE 9 – Choix des algorithmes pour la régression

Type de tâche	Algorithmes possibles
Régression	Linear Regression, Ridge, Lasso, ElasticNet, Random Forest Regressor, Gradient Boosting Regressor

Justification du choix :

- **Régression Linéaire** : Modèle de base, interprétable.
- **Ridge** : Régularisation L2 pour gérer la multicollinéarité.
- **Lasso** : Régularisation L1 pour la sélection de variables.
- **Random Forest** : Modèle non-linéaire, capture les interactions complexes.

3.3 Protocole expérimental

Le protocole expérimental est décrit ci-dessous :

TABLE 10 – Protocole expérimental

Élément	Description
Taille du train set	318 échantillons (80%)
Taille du test set	80 échantillons (20%)
Type de split	Aléatoire (random_state=42)
Validation croisée	Oui, 5 folds (sur les meilleurs modèles)
Pipeline	Oui, ColumnTransformer avec StandardScaler et One-HotEncoder
Bibliothèques principales	pandas, numpy, scikit-learn, matplotlib, seaborn

3.4 Métriques d'évaluation

Les métriques utilisées pour la régression sont :

TABLE 11 – Métriques d'évaluation pour la régression

Métrique	Description
RMSE	Root Mean Squared Error - Erreur quadratique moyenne
MAE	Mean Absolute Error - Erreur absolue moyenne
R^2	Coefficient de détermination (proportion de variance expliquée)

3.5 Résultats obtenus

Les résultats des quatre modèles sont présentés ci-dessous :

TABLE 12 – Comparaison des modèles de régression

Modèle	Train RMSE	Test RMSE	Train R^2	Test R^2
Linear Regression	3.370	2.888	0.819	0.845
Ridge (L2)	3.371	2.889	0.819	0.845
Lasso (L1)	3.438	2.955	0.811	0.838
Random Forest	1.088	2.180	0.981	0.912

Commentaire : Random Forest est le modèle le plus performant avec un R^2 de 0.912 sur le test. Les modèles linéaires sont stables mais moins performants.

3.6 Analyse des erreurs

L'analyse des résidus du modèle Random Forest montre :

- Les résidus sont **centrés autour de 0** (pas de biais systématique).
- Pas de motif clair (non-linéarité acceptable).
- Légère dispersion plus grande pour les prédictions faibles ($\text{mpg} < 20$).

3.7 Importance des variables

L'importance des variables dans le modèle Random Forest est :

TABLE 13 – Importance des variables

Variable	Importance
weight	51.2%
model_year	20.8%
origin_3 (Japon)	11.0%
origin_2 (Europe)	5.5%
horsepower	5.5%
displacement	4.6%
cylinders	1.0%
acceleration	0.4%

3.8 Sélection du meilleur modèle

Le modèle **Random Forest** a été retenu car :

- Il offre le meilleur R^2 sur le test (0.912).
- Il capture les relations non-linéaires.
- Il est robuste face à la multicollinéarité.
- Bien qu'il montre un léger surapprentissage (écart $R^2 = 0.069$), ses performances sur le test restent excellentes.

3.9 Conclusion du chapitre

Quatre modèles de régression ont été comparés. Random Forest est le plus performant avec un R^2 de 0.912. L'analyse de l'importance des variables montre que le poids est le facteur le plus influent. Les résultats ont été validés par une validation croisée à 5 folds. Le chapitre suivant présente l'interprétation des résultats et les limites du travail.

4 Interprétation, limites et reproductibilité

4.1 Introduction du chapitre

Ce chapitre présente l'interprétation des résultats, les limites du projet, les aspects éthiques éventuels et les éléments nécessaires pour reproduire le travail.

4.2 Interprétation des résultats

L'analyse des résultats permet de tirer les conclusions suivantes :

- **Le poids** est la variable la plus influente (51%). Chaque augmentation de 100 lbs réduit la consommation d'environ 0.7 mpg.
- **L'année du modèle** (21%) montre une amélioration significative de l'efficacité énergétique entre 1970 et 1982.
- **L'origine géographique** joue un rôle important : les voitures japonaises sont les plus économes, suivies des européennes, puis des américaines.
- Les relations identifiées sont des **corrélations** et non des causalités. Par exemple, le poids élevé n'est pas la cause directe de la consommation élevée, mais en est un indicateur fort.

4.3 Discussion métier ou applicative

Les résultats de ce projet ont des implications concrètes :

- **Pour les constructeurs** : Réduire le poids est le levier #1 pour améliorer l'efficacité énergétique. Le progrès technologique a permis un gain de ≈ 15 mpg en 12 ans.
- **Pour les consommateurs** : Privilégier les véhicules récents et légers. À caractéristiques égales, les marques japonaises sont plus économes.

4.4 Limites du travail

Les principales limites du projet sont :

- **Dataset daté** : Données de 1970 à 1982 (plus de 40 ans). Ne reflète pas les technologies modernes (hybrides, électriques).
- **Taille modeste** : Seulement 398 observations.
- **Variables manquantes** : Absence de données sur le type de carburant, la transmission, l'aérodynamisme, etc.
- **Multicollinéarité** : Les variables cylindres, déplacement, horsepower, weight sont fortement corrélées.
- **Pas de validation temporelle** : Le split aléatoire ignore l'aspect temporel.

4.5 Améliorations possibles

Les améliorations envisageables sont :

- Utiliser un dataset plus récent (ex : Fuel Economy Data de l'EPA).
- Ajouter des variables modernes (type de carburant, hybridation, transmission).

- Créer des variables dérivées (weight_to_power_ratio, displacement_per_cylinder).
- Tester des modèles plus complexes (XGBoost, LightGBM, réseaux de neurones).
- Utiliser une validation croisée temporelle (TimeSeriesSplit).

4.6 Reproductibilité du projet

Le projet a été conçu pour être reproductible :

TABLE 14 – Informations de reproductibilité

Élément	Information attendue
Lien source du dataset	https://archive.ics.uci.edu/ml/datasets/Auto+MPG
Nom exact du fichier	auto-mpg.data
Chemin relatif	./auto-mpg.data
Version Python	Python 3.11
Bibliothèques	pandas, numpy, scikit-learn, matplotlib, seaborn
requirements.txt	Présent
Instruction d'exécution	pip install -r requirements.txt puis exécution du notebook

4.7 Structure obligatoire du notebook

Le notebook respecte la structure suivante :

TABLE 15 – Structure obligatoire du notebook

Section du notebook	Rôle attendu
01_import_libraries	Importation propre des bibliothèques
02_load_dataset	Chargement du dataset et preuve de la source
03_problem_understanding	Reformulation de la problématique
04_dataset_description	Description des variables, dimensions et cible
05_exploratory_data_analysis	Statistics, visualisations et commentaires
06_data_quality_and_cleaning	Valeurs manquantes, doublons, incohérences et outliers
07_preprocessing	Encodage, normalisation, split et pipeline
08_modeling_or_clustering	Application des méthodes demandées
09_evaluation	Métriques adaptées, tableaux et figures
10_interpretation_and_limits	Interprétation, limites et pistes d'amélioration

4.8 Conclusion du chapitre

Ce chapitre a présenté l'interprétation des résultats, les limites du projet et les pistes d'amélioration. Les résultats montrent que le poids est le facteur le plus influent et que les modèles non-linéaires comme Random Forest sont les plus performants. Les limites principales concernent l'ancienneté des données et la taille modeste du dataset. Le projet est reproductible grâce au notebook et au fichier requirements.txt fournis.

Conclusion générale

Ce projet de Data Mining avait pour objectif de prédire la consommation de carburant des véhicules automobiles à partir de leurs caractéristiques techniques, en utilisant le dataset Auto MPG de l'UCI Machine Learning Repository. La problématique était de déterminer si les variables telles que le poids, la puissance, la cylindrée, le nombre de cylindres, l'année de fabrication et l'origine géographique permettent de prédire efficacement la consommation en miles per gallon.

Le travail réalisé a suivi les étapes classiques du Data Mining. Après une analyse exploratoire approfondie qui a révélé des relations fortes entre le poids et la consommation, nous avons procédé au nettoyage des données (imputation des valeurs manquantes, conservation des outliers) et au prétraitement (standardisation, encodage). Quatre modèles de régression ont été comparés : Régression Linéaire, Ridge, Lasso et Random Forest.

Les résultats montrent que le modèle Random Forest surpasse les modèles linéaires avec un coefficient de détermination R^2 de 0.912 sur l'ensemble de test. L'analyse de l'importance des variables révèle que le poids est le facteur le plus influent (51%), suivi de l'année du modèle (21%) et de l'origine géographique (11% pour les voitures japonaises). Ces résultats confirment que les données techniques des véhicules permettent de prédire leur consommation avec une bonne précision.

Cependant, ce travail présente plusieurs limites. Les données datent de 1970 à 1982 et ne reflètent pas les technologies modernes. La taille du dataset est modeste (398 observations) et certaines variables clés comme le type de carburant ou la transmission sont absentes. De plus, la multicollinéarité entre certaines variables rend l'interprétation individuelle délicate.

Pour améliorer ce travail, plusieurs perspectives sont envisageables : l'utilisation d'un dataset plus récent, l'ajout de variables modernes, la création de variables dérivées, le test de modèles plus complexes (XGBoost, LightGBM) et l'utilisation d'une validation croisée temporelle.

En conclusion, ce projet a permis de mettre en pratique les techniques de Data Mining sur un dataset réel, de comparer différents modèles et d'interpréter les résultats pour en tirer des conclusions métier. Les résultats obtenus confirment l'importance du poids et des facteurs technologiques dans l'efficacité énergétique des véhicules.

Bibliographie et Nétographie

Bibliographie

- 1 QUINLAN, J. Ross. *C4.5 : Programs for Machine Learning*. Morgan Kaufmann, 1993.
- 2 HASTIE, Trevor, TIBSHIRANI, Robert, FRIEDMAN, Jerome. *The Elements of Statistical Learning*. Springer, 2009.

Nétographie

- 3 UCI Machine Learning Repository. *Auto MPG Dataset*. Disponible sur : <https://archive.ics.uci.edu/ml/datasets/Auto+MPG> (consulté le 15 juin 2025).
- 4 Scikit-learn Documentation. *Linear Models*. Disponible sur : https://scikit-learn.org/stable/modules/linear_model.html (consulté le 15 juin 2025).
- 5 Scikit-learn Documentation. *Ensemble Methods*. Disponible sur : <https://scikit-learn.org/stable/modules/ensemble.html> (consulté le 15 juin 2025).

ANNEXES

Annexe A — Notebook

Le notebook Jupyter complet est disponible dans le fichier `projet8_auto_mpg.ipynb`. Il contient l'ensemble du code, des visualisations et des commentaires.

Annexe B — Dataset

Le dataset `auto-mpg.data` est disponible à l'URL suivante :
<https://archive.ics.uci.edu/static/public/9/auto+mpg.zip>

Annexe C — Requirements.txt

```
pandas>=1.3.0
numpy>=1.21.0
matplotlib>=3.4.0
seaborn>=0.11.0
scikit-learn>=1.0.0
```

Annexe D — Figures complémentaires

Les figures suivantes ont été générées lors du projet :




FIGURE 1 – Visualisations de l'analyse exploratoire (EDA)




FIGURE 2 – Matrice de corrélation des variables numériques




FIGURE 3 – Prédictions vs valeurs réelles - Random Forest




FIGURE 4 – Analyse des résidus du modèle Random Forest




FIGURE 5 – Importance des variables dans le modèle Random Forest

Checklist finale avant remise

- Le lien source du dataset est indiqué dans le rapport et dans le notebook.
- Le notebook s'exécute du début à la fin sans erreur.
- Le dataset est chargé avec un chemin relatif ou une méthode reproductible.
- La problématique est clairement formulée.
- La cible est identifiée si le projet est supervisé.
- Les variables sont décrites.
- Les valeurs manquantes sont traitées ou justifiées.
- Les outliers sont analysés.
- Les visualisations sont commentées en français.
- Les choix de nettoyage sont justifiés.
- Les modèles sont adaptés au type de tâche.
- Les métriques sont adaptées au problème.
- Les résultats sont interprétés.
- Les limites sont discutées.
- Le fichier requirements.txt est fourni.
- Les annexes contiennent les éléments complémentaires nécessaires.